

DISCIPLINA: CIÊNCIA E VISUALIZAÇÃO DE DADOS EM SAÚDE

Dinâmica Temporal e Redes de Coexpressão Gênica da Diferenciação de Células-Tronco Embrionárias

Disciplina: Ciência e Visualização de Dados em Saúde
Grupo: COMBI



Integrantes

Luana Lima Rocha, 300615, Biologia

Cristian Leonardo Ferraz Ferreira, 204676, Biologia

Julia de Pietro Bigi, 238163, Biologia/Computação

Diogo Cesar Donadon, 324086, Computação

Pedro Arruda de Oliveira, 300636, Computação



Sumário



INTRODUÇÃO

- Breve resumo do projeto e nossas hipóteses iniciais;
- Metodologia geral e em que ponto estamos.



ESTÁGIO DO PROJETO

- Apresentação da pipeline de pré-processamento;
- Dados gerados.




PRÓXIMOS PASSOS E OBJETIVOS

- O que faremos com os dados gerados;
- Objetivos a serem alcançados.

ABRIL 2026

Introdução



Objetivo

INVESTIGAR A DINÂMICA TEMPORAL E AS REDES DE COEXPRESSÃO GÊNICA DURANTE A DIFERENCIAÇÃO DE CÉLULAS-TRONCO EMBRIONÁRIAS HUMANAS EM **CARDIOMIÓCITOS** E **CÉLULAS PANCREÁTICAS**.

Hipótese

H0: NÃO EXISTEM DIFERENÇAS SIGNIFICATIVAS NOS PADRÕES DE COEXPRESSÃO GÊNICA ENTRE OS ESTÁGIOS TEMPORAIS DA DIFERENCIAÇÃO CELULAR.

H1: EXISTEM MÓDULOS GÊNICOS ESPECÍFICOS QUE REGULAM TRANSIÇÕES CRÍTICAS DURANTE A DIFERENCIAÇÃO DE hESCs




Metodologia Geral




Análise e Coleta dos Dados

Busca na literatura
e *databases*


Metodologia Geral




Metodologia Geral




Metodologia Geral



Metodologia Geral




Metodologia Geral



Estágio do Projeto

- Pré-processamento dos dados
- *Pipeline RNA-seq*





Retirado de: https://biocorecrg.github.io/PHINDaccess_RNAseq_2020/qc_trimming.html

Download das Amostras

Cardiomiócitos



Run	Time	Treatment
SRR30214233	Day 0	cardiomyocyte differentiation
SRR30214243	Day 0	cardiomyocyte differentiation
SRR30214230	Day 3	cardiomyocyte differentiation
SRR30214240	Day 3	cardiomyocyte differentiation
SRR30214224	Day 17	cardiomyocyte differentiation
SRR30214234	Day 17	cardiomyocyte differentiation

<https://www.ebi.ac.uk/ena/browser/view/PRJNA1147293>

Poli hormonais


Run	Time	Treatment
SRR35049363	Day 0	Polyhormonal differentiation
SRR35049353	Day 0	Polyhormonal differentiation
SRR35049360	Day 3	Polyhormonal differentiation
SRR35049350	Day 3	Polyhormonal differentiation
SRR35049344	Day 17	Polyhormonal differentiation
SRR35049354	Day 17	Polyhormonal differentiation

<https://www.ebi.ac.uk/ena/browser/view/SRP610144>




Controle de Qualidade

Controle de Qualidade Inicial




SRR35049350

Read 1





SRR35049350

Read 2



Trimmomatic

Controle de Qualidade Inicial




Trimmomatic

- ILLUMINACLIP:TruSeq3-PE.fa:2:30:10:2:True
- LEADING:20

- TRAILING:20
- MINLEN:50
- SLIDINGWINDOW:4:20

Alinhamento - HISAT2



Adaptado de: <https://www.petagene.com/a-practical-example-of-hisat2-smaller-files-same-tools-faster-analysis/>

FeatureCounts vs StringTie

DOIS PIPELINES DE QUANTIFICAÇÃO DE RNA-SEQ FORAM COMPARADOS EM TEMPO DE EXECUÇÃO E CONSISTÊNCIA DOS RESULTADOS.
FEATURECOUNTS REALIZA CONTAGEM DIRETA DE LEITURAS, ENQUANTO STRINGTIE UTILIZA UM MODELO ESTATÍSTICO BASEADO EM TRANSCRITOS.

FEATURECOUNTS



STRINGTIE



Tempo total: ~25 minutos
Quantificação: ~23 segundos
Mais rápido
Contagem direta (reads → genes)
Baixo custo computacional
Não considera estrutura de transcritos
Menos sensível a isoformas

SRA → prefetch → fasterq-dump →
FASTQ → FastQC → Trimmomatic
→ FastQC → HISAT2 → SAM →
BAM → sort → index →
featureCounts → Counts (genes)

Tempo total: ~23 minutos
Quantificação: ~296 segundos
Modelo baseado em transcritos
Considera isoformas
Maior sensibilidade biológica
Mais lento na quantificação
Mais complexo
computacionalmente


SRA → prefetch → fasterq-dump →
FASTQ → FastQC → Trimmomatic
→ FastQC → HISAT2 (--dta) →
BAM → sort → index → StringTie →
GTF (amostra) → merge → GTF
global → re-estimation → prepDE →
Counts (genes/transcritos)

Dados Gerados




Próximos Passos e Objetivos


Metodologia Geral



Análise de expressão diferencial – DESeq2




Análise de expressão diferencial – DESeq2



Análise de co-expressão e construção de redes:


- Possíveis softwares: NetworkX, GWENA, iGraph, Cytoscape



Análise de co-expressão e construção de redes:

**Detecção e análise de módulos +
enriquecimento dos módulos:
algoritmo de Louvain**

**Análise de super-representação
dos módulos**




Retirado de: <https://doi.org/10.1186/s12859-021-04179-4>

Análise de co-expressão e construção de redes:

**Detecção e análise de módulos +
enriquecimento dos módulos:
algoritmo de Louvain**

**Correlação dos genes: coeficiente
de Spearman**




Análise de co-expressão e construção de redes:

**Deteção e análise de módulos +
enriquecimento dos módulos:
algoritmo de Louvain**

**Correlação dos genes: coeficiente
de Spearman**

**Eigen-values – hubs: matriz de
sobreposição topológica.**




Retirado de: <https://doi.org/10.1186/s12859-021-04179-4>

Anotação e análise de enriquecimento de vias:




Anotação e análise de enriquecimento de vias:




- Classificações ontológicas dos processos biológicos
- Vias biológicas.
- Comparação bancos de dados + testes estatísticos

Anotação e análise de enriquecimento de vias:




Retirado de: <https://doi.org/10.36660/abc.20220874>


Anotação e análise de enriquecimento de vias:



Retirado de: <https://doi.org/10.1186/s12859-021-04179-4>

Possível Resultado Esperado





Obrigado!

Referências

[Bastian et al., 2009] Bastian, M.; Heymann, S.; Jacomy, M. Gephi: an open source software for exploring and manipulating networks. In: Proceedings of the 3rd International AAAI Conference on Web and Social Media. Burnaby, Canada, 2009. p. 361–362.

[Bolger et al., 2014] Bolger, A. M.; Lohse, M.; Usadel, B. Trimmomatic: a flexible trimmer for Illumina sequence data. *Bioinformatics*, v. 30, n. 15, p. 2114–2120, 2014.

[Campbell et al., 2019] Campbell, Madeline et al. Stem cell spheroids. 2019.

[Carlson, 2017] Carlson, M. org.Hs.eg.db: Genome wide annotation for Human. R package version 3.5.0, 2017.

[Dobin et al., 2013] Dobin, A. et al. STAR: ultrafast universal RNA-seq aligner. *Bioinformatics*, v. 29, n. 1, p. 15–21, 2013. doi:10.1093/bioinformatics/bts635.

[Dvash et al., 2006] Dvash, T.; Ben-Yosef, D.; Eiges, R. Human embryonic stem cells as a powerful tool for studying human embryogenesis. *Pediatric Research*, v. 60, p. 111–117, 2006. doi:10.1203/01.pdr.0000228349.24676.17.

[HPSCREG, 2026] HPSCREG. Human Pluripotent Stem Cell Registry. Disponível em: hpscereg.eu. Acesso em: 19 mar. 2026.

[Keskin et al., 2025] Keskin, A.; Shayya, H. J.; Sirabella, D. et al. Temporal multiomics gene expression data of human embryonic stem cell-derived cardiomyocyte differentiation. *Scientific Data*, v. 12, p. 1308, 2025. doi:10.1038/s41597-025-05655-9.

[Keskin et al., 2025a] Keskin, A. et al. Temporal multiomics gene expression data of human embryonic stem cell-derived cardiomyocyte differentiation. NCBI Gene Expression Omnibus (GEO), 2025. Disponível em: <https://identifiers.org/geo/GSE274620>.

[Keskin et al., 2025b] Keskin, A. et al. Temporal multiomics gene expression data across human embryonic stem cell-derived polyhormonal cell differentiation. NCBI Gene Expression Omnibus (GEO), 2025. Disponível em: <https://identifiers.org/geo/GSE305933>.

[Keskin et al., 2026] Keskin, A.; Shayya, H. J.; Patel, A. et al. Temporal multiomics gene expression data across human embryonic stem cell-derived polyhormonal cell differentiation. *Scientific Data*, v. 13, p. 278, 2026. doi:10.1038/s41597-026-06606-8.

[Langfelder; Horvath, 2008] Langfelder, P.; Horvath, S. WGCNA: an R package for weighted correlation network analysis. *BMC Bioinformatics*, v. 9, p. 559, 2008.

[Lee; Lee, 2011] Lee, J. E.; Lee, D. R. Human embryonic stem cells: derivation, maintenance and cryopreservation. *International Journal of Stem Cells*, v. 4, n. 1, p. 9–17, 2011. doi:10.15283/ijsc.2011.4.1.9.

[Love et al., 2014] Love, M. I.; Huber, W.; Anders, S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, v. 15, p. 550, 2014.

[Mao and Mooney, 2015] Mao, Angelo S.; Mooney, David J. Regenerative medicine: Current therapies and future directions. *Proceedings of the National Academy of Sciences*, v. 112, n. 47, p. 14452–14459, 2015.

[Pagès et al., 2025] Pagès, H. et al. AnnotationDbi: manipulation of SQLite-based annotations in Bioconductor. R package version 1.72.0, 2025. Disponível em: <https://bioconductor.org/packages/AnnotationDbi>.

[Pertea et al., 2015] Pertea, M. et al. StringTie enables improved reconstruction of a transcriptome from RNA-seq reads. *Nature Biotechnology*, v. 33, n. 3, p. 290–295, 2015. doi:10.1038/nbt.3122.

[Shannon et al., 2003] Shannon, P. et al. Cytoscape: a software environment for integrated models of biomolecular interaction networks. *Genome Research*, v. 13, n. 11, p. 2498–2504, 2003

Referências

[Thomson et al., 1998] Thomson, J. A. et al. Embryonic stem cell lines derived from human blastocysts. *Science*, v. 282, n. 5391, p. 1145–1147, 1998. doi:10.1126/science.282.5391.1145.

[Trapnell et al., 2014] Trapnell, C. et al. The dynamics and regulators of cell fate decisions are revealed by pseudotemporal ordering of single cells. *Nature Biotechnology*, v. 32, n. 4, p. 381–386, 2014. doi:10.1038/nbt.2859.

[Wen, 2017] Wen, G. A simple process of RNA-sequence analyses by Hisat2, Htseq and DESeq2. In: *Proceedings of the International Conference on Biomedical Engineering and Bioinformatics*. 2017. p. 11–15.

[Wingett; Andrews, 2018] Wingett, S. W.; Andrews, S. FastQ Screen: a tool for multi-genome mapping and quality control. *F1000Research*, v. 7, p. 1338, 2018. doi:10.12688/f1000research.15931.2.

[Yu, 2024] Yu, G. Thirteen years of clusterProfiler. *The Innovation*, v. 5, n. 6, p. 100722, 2024. doi:10.1016/j.xinn.2024.100722.

[Yu, 2026] Yu, G. enrichplot: visualization of functional enrichment result. R package version 1.30.5, 2026. Disponível em: <https://bioconductor.org/packages/enrichplot>.

[Zakrzewski et al., 2019] Zakrzewski, Wojciech et al. Stem cells: past, present, and future. *Stem cell research & therapy*, v. 10, n. 1, p. 68, 2019.

Read QC and trimming. Disponível em: <https://biocorecrg.github.io/PHINDaccess_RNAseq_2020/qc_trimming.html>. Acesso em: 17 abr. 2026.

HISAT2 benchmarked with PetaGene’s compression and transparent readback tools - PetaGene. Disponível em: <<https://www.petagene.com/a-practical-example-of-hisat2-smaller-files-same-tools-faster-analysis/>>. Acesso em: 20 abr. 2026.

LEMOINE, Gwenaëlle G. et al. GWENA: gene co-expression networks analysis and extended modules characterization in a single Bioconductor package. *BMC Bioinformatics*, v. 22, n. 1, p. 267, 25 dez. 2021.

XU, Rui et al. Abordagem de Bioinformática e Biologia de Sistemas para Identificar a Ligação Patogenética entre Insuficiência Cardíaca e Sarcopenia. *Arquivos Brasileiros de Cardiologia*, v. 120, n. 10, 17 out. 2023.

OSIPOVICH, Anna B. et al. A developmental lineage-based gene co-expression network for mouse pancreatic β -cells reveals a role for Zfp800 in pancreas development. *Development*, v. 148, n. 6, 15 mar. 2021.